

TaskNet-ELU: un protocolo experimental de utilidad por byte

para comunicación orientada a tarea

Representaciones compactas, baselines explícitos y una política de transmisión por umbral

Juan Felipe Orozco

Investigación independiente — Ingeniería de Telecomunicaciones

Código y datos: <https://github.com/topassky3/tasknet-elu>

DOI: pendiente de publicación

8 de julio de 2026

Preprint. No revisado por pares.

Resumen

Las redes de comunicación transportan datos sin observar directamente la decisión que esos datos deben habilitar. Este trabajo evalúa, en bancos de prueba controlados, cuánta utilidad de decisión conserva cada byte transmitido y cuándo conviene no transmitir. Se propone y aplica un protocolo experimental para comunicación orientada a tarea: receptores independientes por representación, medición reproducible de bytes según el tipo de representación, *embeddings* cuantizados y reconstruidos antes de evaluar, y veredictos que exigen conservar utilidad antes de premiar eficiencia. En Fashion-MNIST y CIFAR-10, bajo el catálogo de representaciones evaluado, un *embedding* aprendido de 32–64 dimensiones conservó la exactitud del dato completo con 90,2 %–97,4 % menos bytes (0,8925 vs. 0,8895 en Fashion-MNIST; 0,7200 vs. 0,7136 en CIFAR-10). Bajo este protocolo, el *embedding* dominó en Pareto a las representaciones clásicas evaluadas (PNG, JPEG a cinco calidades y reducciones de resolución) y alcanzó una utilidad por byte aproximadamente $7,9\times$ y $19,1\times$ mayor que el mejor clásico que conservó utilidad en Fashion-MNIST y CIFAR-10, respectivamente. En estos dos bancos de prueba, la ventaja relativa aumentó al pasar de Fashion-MNIST a CIFAR-10. Además, una política de transmisión por umbral basada en un estimador de valor marginal frente al silencio redujo 92,0 % los bytes frente a transmitir siempre el dato original con pérdida menor a 3 puntos, y capturó cerca del 88 % del ahorro marginal alcanzable por un oráculo respecto a transmitir siempre el *embedding*. La contribución declarada no es presentar una teoría nueva de comunicación orientada a tarea, sino un protocolo de medición reproducible y honesto, con baselines, oráculo, criterios de éxito y amenazas a la validez explícitos. El código, las tablas y las figuras están disponibles en <https://github.com/topassky3/tasknet-elu>; el DOI de Zenodo queda pendiente de publicación.

1. Introducción

La infraestructura actual de Internet mueve paquetes con eficacia, pero no observa el propósito de esos paquetes: desde la capa de red, una alerta médica, una clase virtual y un video recreativo son

tráfico. Una línea activa de investigación para redes 6G —comunicación semántica y orientada a objetivos [9,8], junto con redes basadas en intención [10]— propone que la red incorpore información sobre la tarea que el dato debe habilitar.

Este trabajo aborda una pregunta operativa dentro de esa visión: *¿cuánta información necesita viajar para que una decisión se conserve, y cuándo el dato no amerita el costo de enviarlo?* El marco de trabajo se denomina TaskNet-ELU, por Energía–Latencia–Utilidad. Su frase guía es motivacional, no un teorema cerrado: *si un dato no mejora la decisión más de lo que cuesta enviarlo, ese dato no debería viajar.*

Posicionamiento. La idea de enviar información en función de su valor para una decisión no es nueva. Se relaciona con el valor de la información [2], el *Information Bottleneck* [3], la teoría tasa–distorsión [4], el metarrazonamiento [5] y la literatura reciente de comunicaciones semánticas y orientadas a tarea [9,8]. La contribución que este trabajo sí reclama es experimental: (i) un protocolo de medición diseñado para reducir sesgos metodológicos y comparaciones engañosas; (ii) mediciones de la frontera utilidad–bytes y de la comparación entre representaciones aprendidas y compresión clásica; (iii) una política de transmisión por umbral evaluada contra baselines y un oráculo; y (iv) criterios de éxito, falsación y amenazas a la validez documentados.

Resumen de contribuciones. En términos operativos, el trabajo aporta: (1) una separación experimental entre representaciones visuales, semánticas, decisión ya tomada y silencio; (2) una regla de medición de bytes reproducible y declarada por familia de representación; (3) una comparación aprendida-vs.-clásica que exige conservar utilidad antes de premiar eficiencia; y (4) una política de transmisión por valor marginal frente al silencio, evaluada contra heurísticas simples y un oráculo.

2. Marco formal resumido

Una fuente produce pares $(X, Y) \sim P_{XY}$: X es el dato observado y Y la variable de tarea. El transmisor emite $Z = \pi_e(X)$, donde Z puede ser una representación transmitida o el símbolo de silencio $\emptyset$; el receptor decide $A = \pi_d(\tilde{Z})$. En estos experimentos se usa utilidad indicadora,

$$u(a, y) = \mathbf{1}\{a = y\}, \quad (1)$$

de modo que la utilidad de una política es la exactitud:

$$U(\pi) = \mathbb{E}\left[u(\pi_d(\tilde{Z}), Y)\right] = \mathbb{P}(A = Y). \quad (2)$$

La utilidad no se atribuye a Z de forma aislada: depende del par codificador–receptor (π_e, π_d) . Por eso el protocolo exige receptores independientes que solo vean la representación evaluada.


Los costos considerados son los bytes esperados $B(\pi)$ de la representación serializada, y proxies declarados de energía y latencia. La forma compuesta usada para razonar sobre costo–utilidad es lagrangiana:

$$J_{\text{ELU}}(\pi) = U(\pi) - \lambda_B B(\pi) - \lambda_E E(\pi) - \lambda_\tau \tau(\pi), \quad \lambda_\bullet \geq 0. \quad (3)$$

En este preprint no se presenta una medición física de energía ni latencia de red: las latencias reportadas son tiempos de inferencia por muestra y se declaran como proxies de cómputo.

Dos objetos organizan el análisis. La frontera utilidad–tasa es

$$U^\star(B) = \sup_{\pi: B(\pi) \leq B} U(\pi), \quad (4)$$



$$u(A, Y) = \mathbf{1}\{A = Y\} \Rightarrow U = \mathbb{P}(A = Y)$$

Figura 1: Escenario experimental. El transmisor observa X y elige una representación Z o silencio; un receptor independiente, que solo ve Z , decide A ; la utilidad premia el acierto frente a Y .

no decreciente y acotada por $U_{\text{máx}}$. Sobre un catálogo discreto de representaciones $\mathcal{R}$, el Punto de Saturación Semántica se mide como

$$\text{SSP}_\varepsilon = \arg \min_{r \in \mathcal{R}} B_r \quad \text{s.a.} \quad U_r \geq U_{\text{máx}} - \varepsilon, \quad \varepsilon = 0,03. \quad (5)$$

Este SSP empírico es una cota superior del mínimo real: otra representación no incluida en $\mathcal{R}$ podría lograr igual utilidad con menos bytes. Por tanto, el trabajo no afirma encontrar un mínimo teórico absoluto. También se distingue la frontera *óptima* $U^*(B)$ de los puntos crudos medidos: la frontera teórica es no decreciente, mientras que las representaciones evaluadas pueden mostrar relaciones no monótonas entre bytes y utilidad.

El respaldo conceptual viene del principio de suficiencia: si $T = t(X)$ es suficiente para Y en el sentido $Y \perp X \mid T$, entonces la utilidad óptima alcanzable desde T puede igualar la alcanzable desde X . Un *embedding* aprendido puede interpretarse como estadístico aproximadamente suficiente para la tarea, pero al provenir de un transmisor entrenado en la tarea debe considerarse una cota optimista.

Finalmente, la política por muestra se motiva con una regla de valor marginal: transmitir cuando la ganancia esperada frente al silencio excede el costo en unidades de utilidad,

$$\Delta U(x) > \lambda C(x). \quad (6)$$

La Fase 4 no observa $\Delta U(x)$ directamente; usa un score barato basado en el softmax del transmisor y lo compara contra heurísticas y un oráculo no desplegable.

3. Protocolo experimental

El protocolo tiene cuatro reglas principales.

Receptor independiente. Cada representación accionable se evalúa con un modelo receptor entrenado por separado que solo ve esa representación. Esto evita evaluar un *embedding* con la misma red que lo produjo. La etiqueta se mide contra la verdad de terreno porque representa una decisión ya tomada. El silencio usa la clase mayoritaria del conjunto de entrenamiento.

Medición reproducible de bytes. Para vectores, *embeddings*, etiquetas y representaciones tipo matriz `uint8`, se usa cuantización a `uint8` y gzip. Para PNG/JPEG se usa el tamaño real del contenedor de imagen. Esta medición no es una estimación perfecta de entropía; es una regla de medición declarada, reproducible y consistente por familia de representación.

Se mide lo que viajaría. El *embedding* se cuantiza a `uint8`, se serializa, se reconstruye, y el receptor se entrena y evalúa sobre la versión reconstruida. Los parámetros mínimo/máximo del

Cuadro 1: Fase 1 (Fashion-MNIST). Exactitud media $\pm$ desviación estándar entre 3 semillas.

Representación	Bytes	Exactitud	Utilidad/byte	Ahorro
original (PNG)	512,4	$0,8895 \pm 0,0016$	0,00174	—
resize 16×16	212,3	$0,8577 \pm 0,0038$	0,00404	58,6 %
resize 8×8	78,8	$0,7894 \pm 0,0052$	0,01002	84,6 %
embedding	50,4	$0,8925 \pm 0,0028$	0,01771	90,2 %
etiqueta	21,0	$0,8876 \pm 0,0030$	0,04227	95,9 %
silencio	0,0	0,1000	—	100 %

cuantizador se asumen compartidos de antemano como metadatos de calibración y no se cuentan por muestra.

Veredictos condicionados a conservar utilidad. Una representación no se declara ganadora solo por tener alta utilidad por byte: primero debe conservar utilidad dentro de $\varepsilon = 0,03$ del máximo observado. La dominancia de Pareto se reporta por separado. Las heurísticas de transmisión se comparan mediante curvas completas, no con umbrales elegidos a mano.

Los experimentos se ejecutaron en CPU con PyTorch. Se usaron CNN compactas: dos o tres bloques convolucionales, *embedding* de 32 dimensiones en Fashion-MNIST y 64 dimensiones en CIFAR-10. Los receptores vectoriales son MLP pequeños.

4. Fase 1: frontera utilidad–bytes en Fashion-MNIST

Se comparan seis representaciones con receptor independiente: imagen original, **resize_16x16**, **resize_8x8**, *embedding*, etiqueta y silencio. La corrida principal usa Fashion-MNIST completo, 5 épocas, 3 semillas y backend `torch`. La Tabla 1 resume los resultados.

Lectura. El *embedding* es el SSP semántico dentro del catálogo evaluado: conserva la utilidad del dato completo con 90,2 % menos bytes. La etiqueta aparece como SSP general/de decisión porque representa una decisión ya tomada; no es una representación semántica reutilizable y no debe tratarse como equivalente al *embedding*. No aparece SSP visual: las reducciones de imagen no conservan utilidad con ahorro suficiente. Un punto relevante es que **resize_8x8** pesa más que el *embedding* (78,8 vs. 50,4 bytes) y obtiene bastante menos exactitud. Es decir, los puntos observados no siguen una relación monótona simple: más bytes no implican automáticamente más utilidad. Bajo esta tarea, la organización de la información en la representación pesa más que el tamaño bruto.

5. Fase 2: representación aprendida vs. compresión clásica

La Fase 2 compara el *embedding* contra PNG, JPEG a calidades $\{90, 50, 20, 10, 5\}$ y reducciones de resolución, todas evaluadas con receptores independientes entrenados sobre las representaciones reconstruidas. La corrida usa Fashion-MNIST completo, 5 épocas y 3 semillas. La Tabla 2 y la Figura 2 resumen los resultados principales.

Veredicto. Bajo este protocolo y el catálogo evaluado, el *embedding* domina en Pareto a las representaciones clásicas: obtiene mayor exactitud que los clásicos con menos bytes. Entre los




Figura 2: Fase 1: utilidad vs. bytes en Fashion-MNIST. Los puntos empíricos observados no tienen por qué ser monótonos; la lectura relevante es la envolvente/frontera empírica entre utilidad y bytes.

Cuadro 2: Fase 2 (Fashion-MNIST), filas seleccionadas.

Representación	Bytes	Exactitud	Utilidad/byte
original (PNG)	512,5	0,8859	0,00173
JPEG q90	742,9	0,8851	0,00119
JPEG q5	383,5	0,8622	0,00225
resize 8×8	78,8	0,7984	0,01014
embedding	50,4	0,8916	0,01769

clásicos que conservan utilidad dentro de $\varepsilon = 0,03$, JPEG q5 es el mejor por utilidad por byte, aunque entra en la tolerancia por poco (0,8622 frente a $U_{\text{máx}} \approx 0,8916$). El *embedding* pesa 50,4 bytes y obtiene 0,8916 de exactitud; JPEG q5 pesa 383,5 bytes y obtiene 0,8622. La utilidad por byte del *embedding* es aproximadamente 7,9 veces la de JPEG q5.

El caso **resize_8x8** ilustra por qué el veredicto exige conservar utilidad: aunque su utilidad por byte supera a la de los JPEG, su exactitud cae a 0,7984, fuera de la tolerancia. Por tanto, no se considera ganador.

6. Fase 3: validación en CIFAR-10

La Fase 3 repite la comparación en CIFAR-10, un banco de prueba más complejo que Fashion-MNIST dentro de este estudio: color, texturas y fondos. También es un escenario más favorable para JPEG que las imágenes 28×28 en escala de grises. La corrida usa CIFAR-10 completo, 10 épocas, 3 semillas y CPU. La Tabla 3 y la Figura 3 resumen los resultados principales.

Lectura. El patrón observado en Fashion-MNIST persiste en CIFAR-10 bajo el protocolo evaluado:




Figura 3: Fase 2: frontera aprendido vs. clásico en Fashion-MNIST.

Cuadro 3: Fase 3 (CIFAR-10), filas seleccionadas.

Representación	Bytes	Exactitud	Utilidad/byte
original (PNG)	2267,7	0,7136	0,00031
JPEG q90	1106,2	0,6963	0,00063
JPEG q5	670,8	0,5732	0,00085
resize 8×8	211,7	0,5340	0,00252
embedding	59,8	0,7200	0,01203
etiqueta	21,0	0,7057	0,03360

el *embedding* conserva utilidad dentro de ε y pesa 59,8 bytes, frente a 2267,7 bytes del PNG original. El ahorro respecto al original sube de 90,2 % en Fashion-MNIST a 97,4 % en CIFAR-10. En estos dos bancos de prueba, la ventaja relativa del *embedding* frente al mejor clásico que conserva utilidad aumentó: en CIFAR-10 el mejor clásico dentro de ε es JPEG q90, con utilidad por byte 0,0006295; el *embedding* alcanza 0,012034, una razón aproximada de 19,1×.

Esta observación no debe leerse como ley universal sobre fuentes complejas. Indica que, en estos dos bancos y con estos modelos, la representación orientada a tarea escaló mejor que las representaciones visuales evaluadas. Las exactitudes absolutas son menores que en Fashion-MNIST porque CIFAR-10 es más difícil y las CNN usadas son compactas.

7. Fase 4: política de transmisión por umbral

Las fases anteriores preguntan *qué* representación conviene transmitir. La Fase 4 pregunta *cuándo* conviene transmitir. Para cada muestra de test, el transmisor elige entre silencio y transmitir el *embedding*. El silencio equivale a una decisión por clase mayoritaria del conjunto de entrenamiento.




Figura 4: Fase 3: utilidad vs. bytes en CIFAR-10, por familia de representación.

Como $\Delta U(x)$ no se conoce en despliegue, se usa un score barato basado en el softmax del transmisor:

$$\widehat{\Delta U}(x) = p_{tx}(\text{clase top} \mid x) - p_{tx}(\text{clase mayoritaria} \mid x). \quad (7)$$

Este score no es utilidad real ni probabilidad calibrada: es un estimador de valor marginal frente a callar. La diferencia con la heurística de confianza es central. La confianza baja transmite cuando el modelo duda; ELU transmite cuando el envío parece aportar valor frente al silencio. Una muestra difícil puede tener baja confianza pero seguir siendo poco valiosa de transmitir si el receptor también fallará. Una muestra segura pero no mayoritaria puede ser valiosa, porque callar probablemente falla.

La política transmite la fracción q de muestras con mayor $\widehat{\Delta U}$, barriendo q . Se compara contra transmitir siempre el dato original, transmitir siempre el *embedding*, transmitir siempre la etiqueta, nunca transmitir, una heurística de baja confianza y un oráculo que usa la verdad de terreno. La corrida se hace en Fashion-MNIST, 5 épocas y 3 semillas. La Tabla 4 y la Figura 4 resumen los resultados principales.

Resultados. El mejor punto ELU dentro de ε obtiene utilidad 0,8696 con 41,1 bytes medios, transmitiendo 83,3 % de las muestras. Frente a transmitir siempre la imagen original, reduce bytes en 92,0 % con pérdida menor a 3 puntos. Frente a transmitir siempre el *embedding*, el ahorro marginal es 16,8 %. El oráculo alcanza un ahorro marginal de 19,1 % respecto a siempre-*embedding*; por tanto, la política ELU captura aproximadamente el 88 % de ese ahorro marginal no desplegable.

La comparación con confianza muestra que valor marginal e incertidumbre no son equivalentes. A fracción transmitida igualada ($q = 0,500$), ELU obtiene 0,5963 de utilidad frente a 0,4134 de la heurística de baja confianza. En la curva evaluada, ELU domina a confianza. Este resultado depende del score usado, del respaldo por clase mayoritaria y de la calibración no explícita del softmax; por ello se reporta como evidencia empírica, no como garantía universal.

Cuadro 4: Fase 4: políticas de transmisión. Promedios sobre 3 semillas. La reducción de bytes se mide frente a transmitir siempre la imagen original.

Política	Utilidad	Bytes medios	Fracción transmitida	Reducción
Transmitir todo (original)	0,8895	511,8	100 %	0 %
Siempre <i>embedding</i>	0,8913	49,4	100 %	90,3 %
Etiqueta (referencia) ^a	0,8876	21,0	100 %	95,9 %
Silencio (referencia) ^a	0,1000	0,0	0 %	100 %
Confianza ($q = 0,500$)	0,4134	24,9	50 %	95,1 %
ELU ($q = 0,500$)	0,5963	24,5	50 %	95,2 %
ELU (mejor punto en ε)	0,8696	41,1	83,3 %	92,0 %
Oráculo ($\Delta U_{\text{real}} > 0$) ^b	0,9103	40,0	81,0 %	92,2 %

^aLa etiqueta y el silencio son referencias, no representaciones equivalentes al dato: la etiqueta presupone una decisión ya tomada y el silencio usa la clase mayoritaria. ^bEl oráculo usa verdad de terreno y no es desplegable.

Cuadro 5: Criterios operativos del proyecto acotado, evaluados en las corridas reportadas.

Criterio	Evidencia	Estado
Una representación reduce $\geq 80\%$ los bytes con pérdida ≤ 3 puntos	<i>Embedding</i> : 90,2 %–97,4 % de ahorro (F1–F3)	✓
Una representación aprendida supera a la compresión clásica en utilidad por byte, conservando utilidad	$\sim 7,9\times$ (F2) y $\sim 19,1\times$ (F3) frente al mejor clásico dentro de ε	✓
La política por umbral reduce $\geq 50\%$ los bytes con pérdida controlada	92,0 % frente a transmitir todo (F4)	✓
El patrón de saturación utilidad–bytes es estable a través de semillas en las corridas principales	Las desviaciones observadas son del orden de 10^{-3} – 10^{-2} y menores que las diferencias principales reportadas	✓

8. Criterios operativos de éxito y falsación

Los criterios operativos definidos para el proyecto acotado se cumplieron en estas corridas. La Tabla 5 resume la evidencia. Estos criterios no sustituyen una evaluación externa: delimitan qué se consideraría evidencia favorable o desfavorable dentro de este laboratorio.

Los desenlaces de falsación estaban definidos: que el *embedding* no conservara utilidad, que un clásico dominara al *embedding*, que el codo desapareciera en CIFAR-10, o que la política por umbral no superara una heurística simple. En estas corridas no ocurrieron. El resultado negativo más informativo fue la ausencia de SSP visual: reducir la imagen de forma directa no conservó la decisión con ahorro suficiente.

9. Reproducibilidad y artefactos

El código, las tablas, los reportes y las figuras se encuentran disponibles en el repositorio público:

<https://github.com/topassky3/tasknet-elu>

El DOI de Zenodo queda pendiente de publicación.




Figura 5: Fase 4: bytes medios vs. utilidad. La política ELU domina a la heurística de baja confianza en la curva evaluada y se aproxima al oráculo.

Estado actual de disponibilidad. Los resultados reportados provienen de los CSV generados por los scripts indicados en cada fase. El repositorio incluye las tablas, las figuras, los reportes de fase y los scripts principales de reproducción.

Artefactos disponibles. El repositorio incluye scripts ejecutables y autocontenidos por fase, tablas CSV, figuras generadas por los scripts, informes y cierres de fase en Markdown, y un archivo `requirements.txt` con dependencias. Los scripts relevantes son `01_utility_per_bit_fashion_mnist.py`, `02_learned_vs_classic.py`, `03_cifar10_validation_v3.py` y `04_elu_threshold_policy.py`.

Hardware y determinismo. Las corridas reportadas se obtuvieron en CPU con PyTorch. Cada fase usa semillas explícitas y reporta medias y desviaciones estándar entre tres semillas. Fashion-MNIST y CIFAR-10 se descargan mediante `torchvision`. Los comandos definitivos de reproducción quedan documentados en el README del repositorio.

Figuras. Este archivo LaTeX referencia nombres reales generados por los scripts y ubicados en `results/figures/`:

- `accuracy_vs_bytes.png`
- `phase2_learned_vs_classic_frontier.png`
- `phase3_accuracy_vs_bytes.png`
- `phase4_traffic_utility.png`

10. Amenazas a la validez

Validez interna. El *embedding* proviene de un transmisor entrenado en la tarea; por tanto, su ventaja es una cota optimista aunque el receptor sea independiente. El softmax usado en Fase 4 no fue calibrado explícitamente, de modo que $\widehat{\Delta U}$ debe interpretarse como score, no como utilidad verdadera. Los parámetros del cuantizador se asumen compartidos como metadatos y no se cuentan por muestra. El bit de señalización transmitir/callar no se contabiliza.

Validez de constructo. gzip es una regla de medición reproducible, no un compresor óptimo ni una estimación exacta de entropía. La latencia reportada es inferencia del receptor por muestra, no latencia de red ni energía física. El SSP empírico depende del catálogo de representaciones evaluado y no prueba un mínimo teórico absoluto.

Validez externa. Fashion-MNIST y CIFAR-10 son bancos de laboratorio; los resultados no se generalizan automáticamente a redes reales, datos multimodales, canales con ruido, tráfico multi-usuario o tareas con costos asimétricos. Los modelos usados son pequeños y fueron ejecutados en CPU.

Fase 4. El silencio se implementa como clase mayoritaria, lo que limita el ahorro marginal posible en datasets balanceados. El oráculo usa verdad de terreno y solo sirve como techo no desplegable.

11. Limitaciones

Este trabajo debe leerse como una prueba experimental acotada, no como una teoría general de redes orientadas a tarea. La comparación contra JPEG/PNG es informativa, pero no cubre todos los codecs, autoencoders, técnicas de compresión neuronal ni esquemas de comunicación con canal real. Tampoco se mide energía física, congestión, colas, retransmisiones ni latencia de red. La política ELU se evalúa en clasificación balanceada; tareas con clases desbalanceadas, costos de error distintos o utilidad no binaria podrían cambiar la regla operativa.

12. Trabajo relacionado

La medición de información y los límites de la compresión se remontan a Shannon [1]. El valor de la información para decisiones se formaliza desde Howard [2]. El *Information Bottleneck* [3] comprime X conservando información relevante para Y . La teoría tasa-distorsión [4] minimiza tasa sujeta a distorsión; en este trabajo, la distorsión se induce por la tarea mediante pérdida de utilidad de decisión, no por fidelidad visual. Las comunicaciones semánticas y orientadas a objetivo [9,8] y las redes basadas en intención [10] desarrollan la visión de sistema. El metarrazonamiento de Russell y Wefald [5] formaliza decisiones computacionales basadas en valor esperado y costo; la regla $\Delta U > \lambda C$ puede verse como una instancia de esa idea aplicada a transmisión.

13. Trabajo futuro

Cuatro extensiones son inmediatas. Primero, evaluar extractores no entrenados en la tarea para reducir la cota optimista del *embedding*. Segundo, aplicar el mismo instrumento de cuantización y compresión a los pesos W del modelo, barriendo el tamaño del conjunto de entrenamiento, para

explorar la relación entre bytes comprimidos de pesos, brecha de generalización y SSP de la tarea, en diálogo con cotas informacionales de generalización [11]. Tercero, aplicar una regla de valor marginal a asignación de cómputo, por ejemplo en búsqueda de ajedrez, donde el costo es número de nodos y la utilidad es mejora de decisión. Cuarto, construir un simulador multi-nodo con varios transmisores compitiendo por un presupuesto de canal, para acercar el protocolo a redes orientadas a intenciones.

14. Conclusión

Bajo un protocolo experimental reproducible y un catálogo declarado de representaciones, este trabajo midió que una representación semántica compacta puede conservar la decisión con 90,2 %–97,4 % menos bytes que el dato completo en Fashion-MNIST y CIFAR-10. En estos bancos, el *embedding* dominó en Pareto a las representaciones clásicas evaluadas y obtuvo mayor utilidad por byte que el mejor clásico que conservó utilidad. Además, una política de transmisión por umbral basada en un score de valor marginal frente al silencio redujo 92,0 % los bytes respecto a transmitir siempre el dato original con pérdida menor a 3 puntos, y capturó cerca del 88 % del ahorro marginal alcanzable por un oráculo respecto a transmitir siempre el *embedding*. Estos resultados no prueban una ley universal; aportan evidencia controlada de que medir utilidad por byte y valor marginal puede convertir una idea conocida de comunicación orientada a tarea en un protocolo evaluable, falsable y reproducible. El paso siguiente no es ampliar los claims, sino publicar artefactos, facilitar reproducción independiente y probar variantes menos optimistas del transmisor.

Referencias

- [1] C. E. Shannon, “A Mathematical Theory of Communication”, *Bell System Technical Journal*, vol. 27, 1948.
- [2] R. A. Howard, “Information Value Theory”, *IEEE Transactions on Systems Science and Cybernetics*, vol. 2, no. 1, 1966.
- [3] N. Tishby, F. C. Pereira, W. Bialek, “The Information Bottleneck Method”, *Proc. 37th Allerton Conference*, 1999.
- [4] T. Berger, *Rate Distortion Theory: A Mathematical Basis for Data Compression*, Prentice-Hall, 1971.
- [5] S. Russell, E. Wefald, “Principles of Metareasoning”, *Artificial Intelligence*, vol. 49, 1991.
- [6] H. Xiao, K. Rasul, R. Vollgraf, “Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms”, arXiv:1708.07747, 2017.
- [7] A. Krizhevsky, “Learning Multiple Layers of Features from Tiny Images”, technical report, University of Toronto, 2009.
- [8] E. Calvanese Strinati, S. Barbarossa, “6G Networks: Beyond Shannon Towards Semantic and Goal-Oriented Communications”, *Computer Networks*, vol. 190, 2021.
- [9] D. Gündüz *et al.*, “Beyond Transmitting Bits: Context, Semantics, and Task-Oriented Communications”, *IEEE Journal on Selected Areas in Communications*, vol. 41, no. 1, 2023.
- [10] A. Clemm *et al.*, “Intent-Based Networking — Concepts and Definitions”, RFC 9315, IETF, 2022.

- [11] A. Xu, M. Raginsky, “Information-Theoretic Analysis of Generalization Capability of Learning Algorithms”, *NeurIPS*, 2017.